

REPORTE ANALÍTICO: ARQUITECTURA Y PESADO SEMÁNTICO (TF-IDF)

1. PREÁMBULO

Este informe expone el flujo de trabajo diseñado para la destilación de conocimiento en un conjunto de textos sobre informática. El propósito central es convertir cadenas de texto crudo en representaciones matemáticas (vectores), facilitando la distinción entre el léxico genérico y los descriptores críticos mediante la métrica estadística TF-IDF.

2. ESTRATEGIA DE TRATAMIENTO DE DATOS

El flujo de ingeniería lingüística se dividió en los siguientes nodos operativos:

- **A. Segmentación Léxica:** División del flujo textual en componentes discretos para su análisis atómico.
- **B. Depuración de Señal:** Filtrado de conectores y caracteres especiales para reducir la entropía y enfocarse en el contenido sustantivo.
- **C. Clasificación Morfosintáctica:** Etiquetado de tipos de palabras para contextualizar el proceso de normalización.
- **D. Reducción Canónica:** Transformación de variantes léxicas a su forma base morfológica apoyada en la base de datos semántica WordNet.

3. DIAGNÓSTICO DE HALLAZGOS

3.1. Ordenamiento de Relevancia (Top 6)

El inventario de frecuencia revela los ejes temáticos que articulan el documento:

1. Python (7 registros)
2. Javascript (7 registros)

3. Cplus (5 registros)
4. Rust (5 registros)
5. Interpret (3 registros)
6. Language (3 registros)

El valor atípico mínimo o **"outlier" de baja frecuencia** correspondió al término *'programmer'*, detectado en una única oportunidad (1).

3.2. Densidad Léxica Intra-oracional

Se localizaron términos con alta densidad local, afectando directamente el factor de frecuencia de término (TF):

- **Bloque 1:** Language
- **Bloque 3:** Typed
- **Bloque 8:** Require, Compilation

3.3. Histograma de Concentración Semántica

La representación gráfica de las frecuencias valida que la carga de información se agrupa en torno a las tecnologías de desarrollo modernas, donde los lenguajes de script lideran la tendencia.

4. VALIDACIÓN DEL MODELO PROBABILÍSTICO

La aplicación de la matriz de ponderación confirma el comportamiento esperado del algoritmo de discriminación:

- **Efecto de Saturación:** Palabras con alta recurrencia (ej. "Python") ven su valor atenuado (≈ 0.15). Esto ocurre porque el modelo asume que un término presente en casi todas partes pierde su poder para clasificar o distinguir secciones específicas.
- **Efecto de Especificidad:** Las palabras únicas (frecuencia 1) escalan hasta los niveles máximos de importancia (≈ 0.60). El motor las prioriza al considerarlas las etiquetas más precisas para definir el tema de una frase.

5. SÍNTESIS FINAL

El sistema opera como un ecualizador de importancia semántica. Gracias al cálculo TF-IDF, se logra automatizar la separación entre la "paja" comunicativa (valores bajos como 0.27) y la "médula" técnica (valores altos como 0.67). En conclusión, la herramienta permite ignorar la redundancia lingüística para centrar la capacidad de cómputo en los conceptos que realmente aportan significado al análisis.

Documento generado para análisis de procesamiento de lenguaje natural y minería de textos.